信息检索基础

Fundamental of Information Retrieval

第6讲 Web搜索

Web Search

提纲

1. 上一讲回顾
2. 互联网发展趋势
3. 互联网广告
4. 重复检测

小结

- **信息检索的评价方法**
  - **不考虑序检索评价指标(即基于集合)**
    - **P、R、F_1、Accuracy**
  - **考虑序的评价指标**
    - **R-Precion、P-R曲线、AP（Average Precision）、P@N**

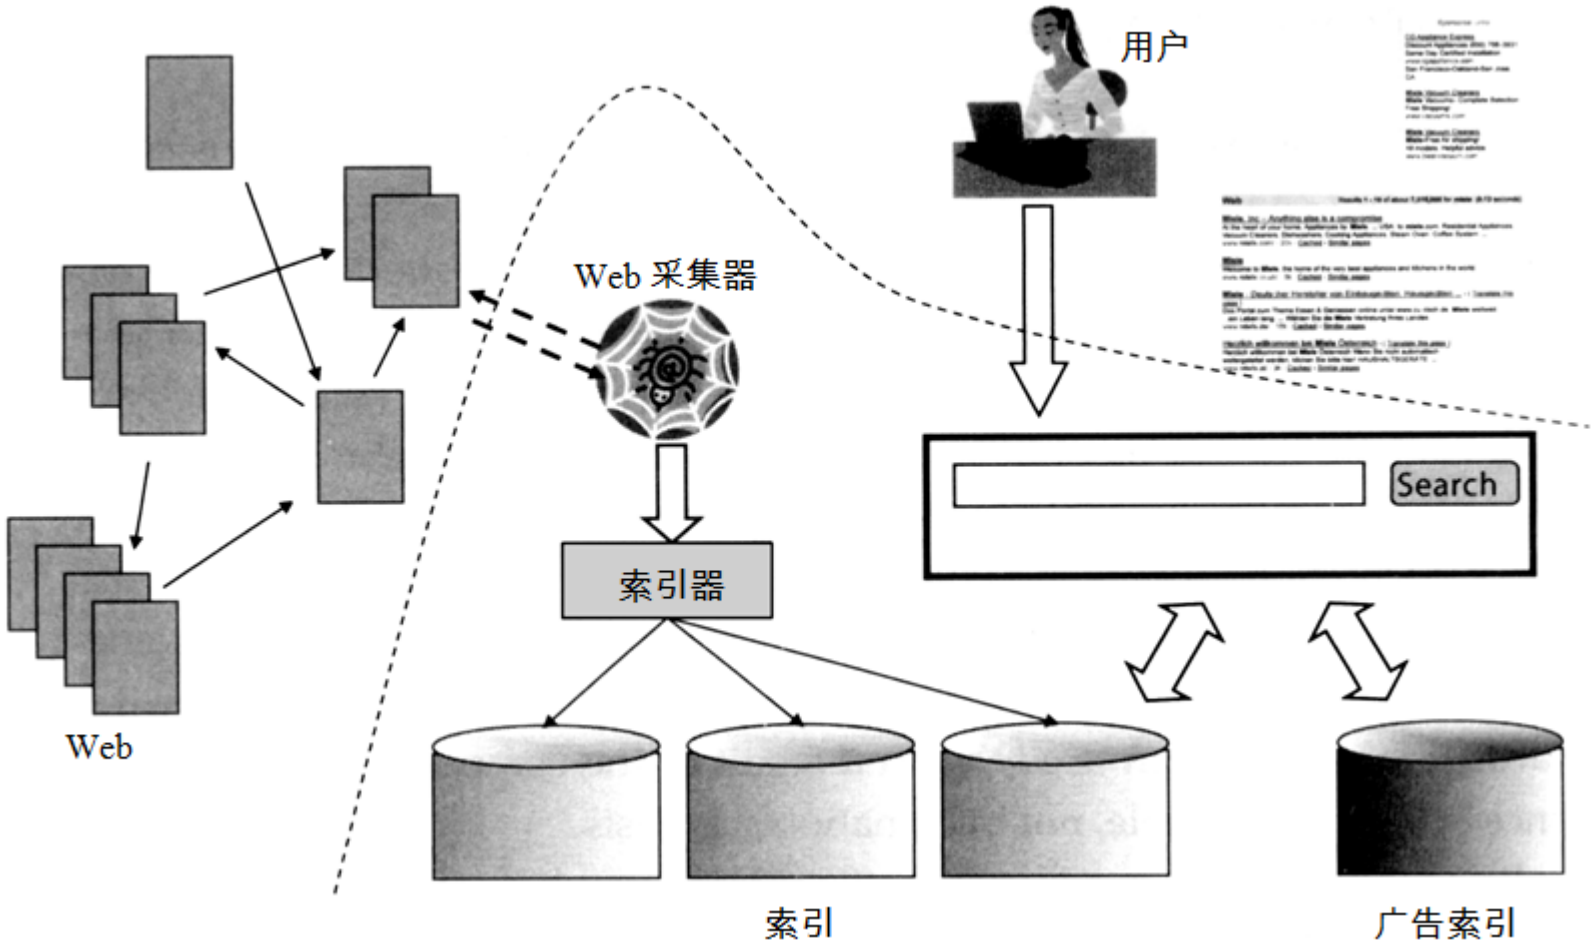
评价指标分类- Part B

- 对单个查询进行评估的指标
  - 在单个查询上检索系统的得分
- 对多个查询进行评估的指标
  - 在多个查询上检索系统的得分求平均
    - 宏平均 Macro
    - 微平均 Micro

提纲

1. 上一讲回顾
2. 互联网发展趋势
3. 互联网广告
4. 重复检测

Web搜索系统组成



搜索是Web上使用最多的应用之一

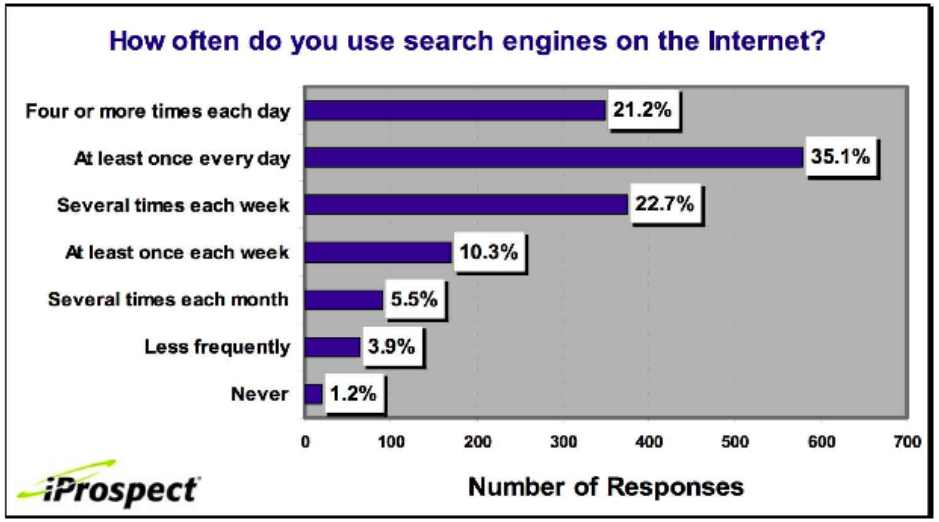
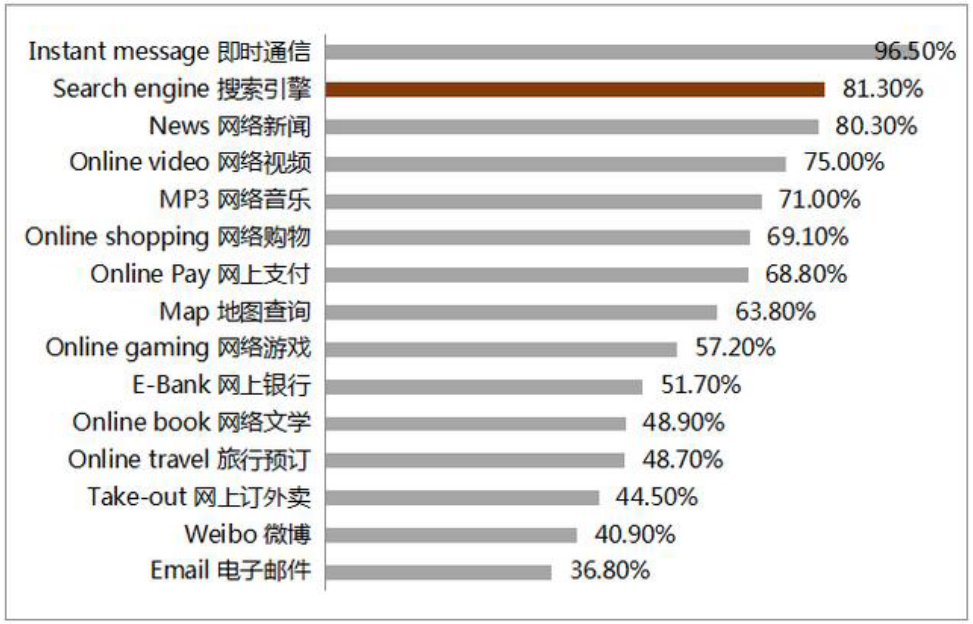


图6：中国搜索引擎用户规模及使用率

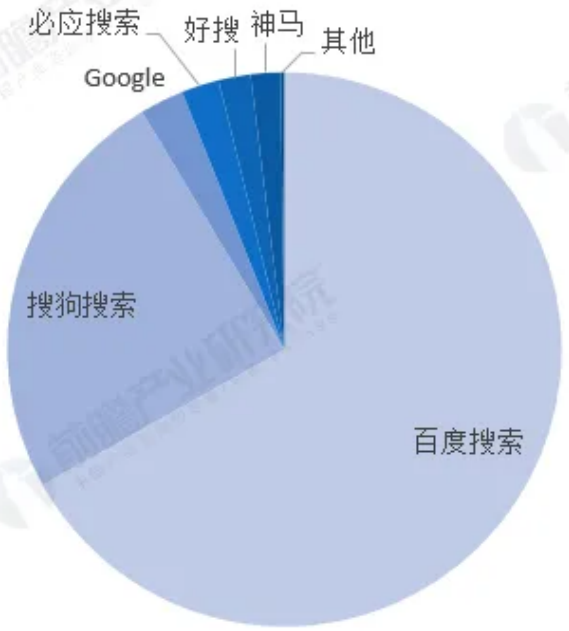


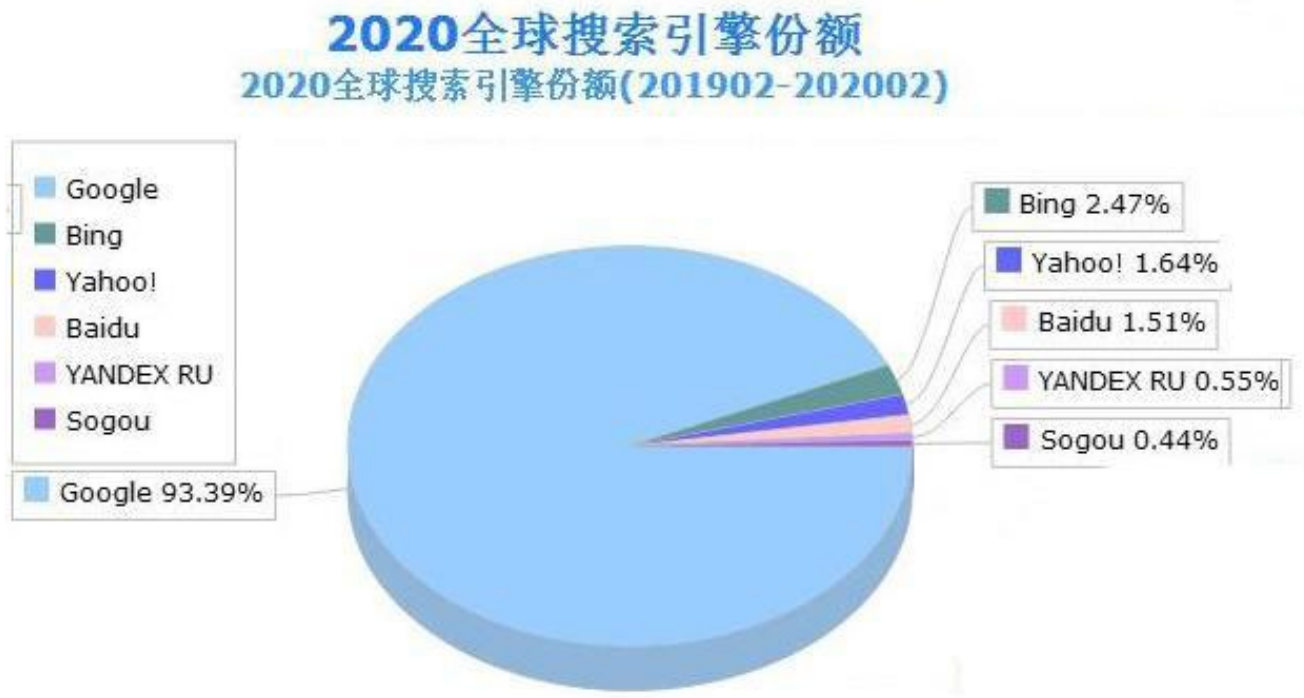
中国网民各类互联网应用的使用率



搜索是Web上使用最多的应用之一

图表4：2020年中国搜索引擎行业市场份额结构(单位：%)





没有搜索引擎，Web甚至无法运转

- 没有搜索，很难找到所需的内容
- → 没有搜索，在Web上创建内容也就缺了动机
  - 如果没人看为什么要发布内容?
  - 如果没有任何回报为什么要发布内容?
- Web上必须要有人买单
  - 服务器、Web基础设施、内容创建过程等需要费用支持
  - 这些费用的大部分都是通过搜索广告支付
  - 可以说，搜索为Web买单

兴趣聚合(Interest aggregation)

- **Web的特点：具有相同兴趣或需求的人，即使所处地理位置分散，也可以通过Web找到对方**
  - **开源项目和社区：GitHub、CSDN**
  - **滴水筹、轻松筹**
- **搜索引擎是实现兴趣聚合（需求聚合）的关键事物**

Web IR vs. 一般的IR

- 在Web上，搜索不仅仅是一个好的特点
  - 搜索是Web的关键事物
  - 筹资、内容创建、兴趣聚合等等

  → 参考搜索广告
- Web是一个充满噪声数据且组织失调的集合体
  - → 大量的重复需要检测
- 用户可以无控制和无限制地发布内容
  - → 大量作弊内容需要检测
- Web规模非常大
  - → 需要知道Web的规模大小

提纲

1. 上一讲回顾
2. 互联网发展趋势
3. 互联网广告
4. 重复检测

第一代搜索广告: Goto (1996) 竞价排名



about Real Estate

第一代搜索广告: Goto (1996)



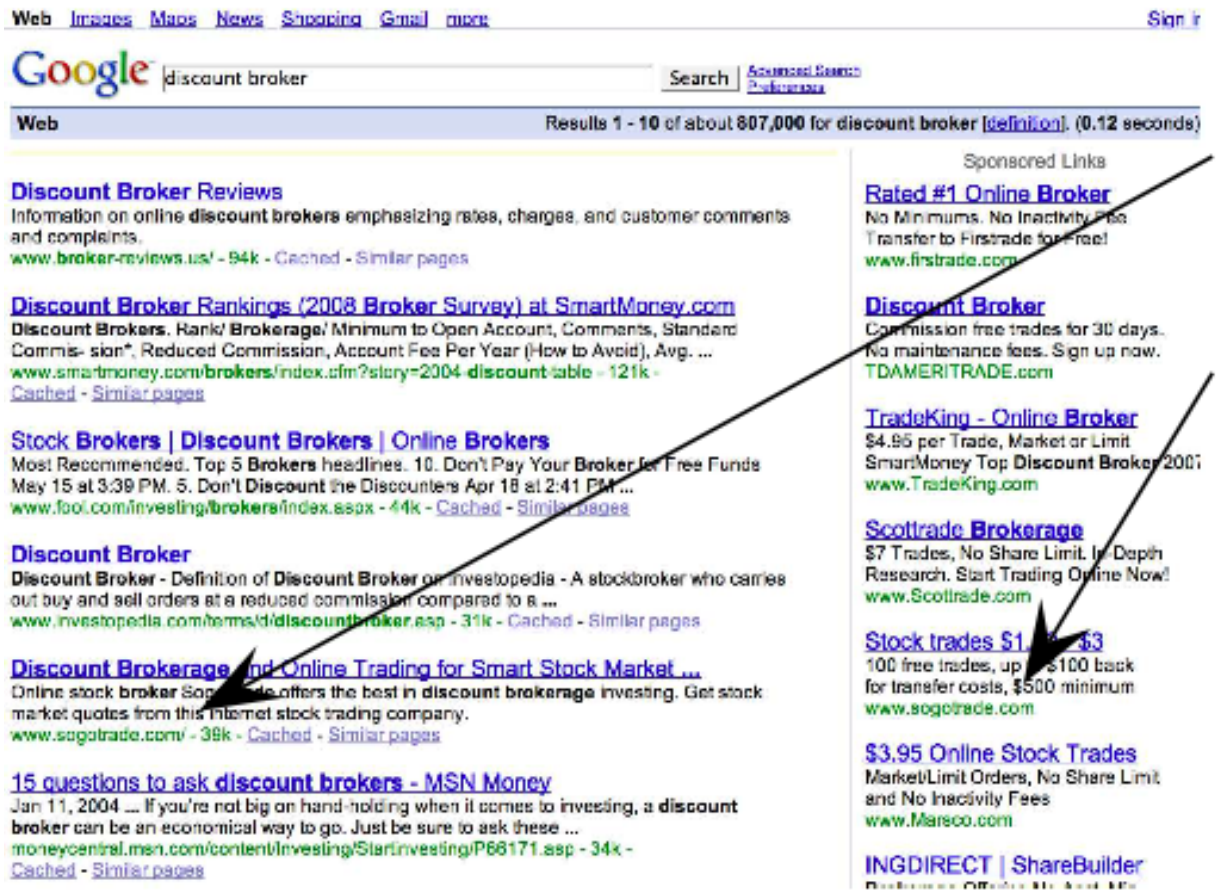
- Buddy Blake 为此搜索投出最高价 ($0.38)
- 只要某个人点击了该链接，Buddy Blake就要付$0.38的费用给 Goto 公司
- **搜索结果按照投标价格的顺序排序** – Goto可以获得最大的收益
- **不区分广告还是文档，仅仅是一个结果列表!**
- 广告预售，坦诚公开，**没有相关度排序**
- Goto并不假装存在相关度

第二代搜索广告: Google (2000/2001)

特点:

- **严格区分搜索结果和搜索广告**

两个列表结果: web 网页 (左图) 及广告 (右图)



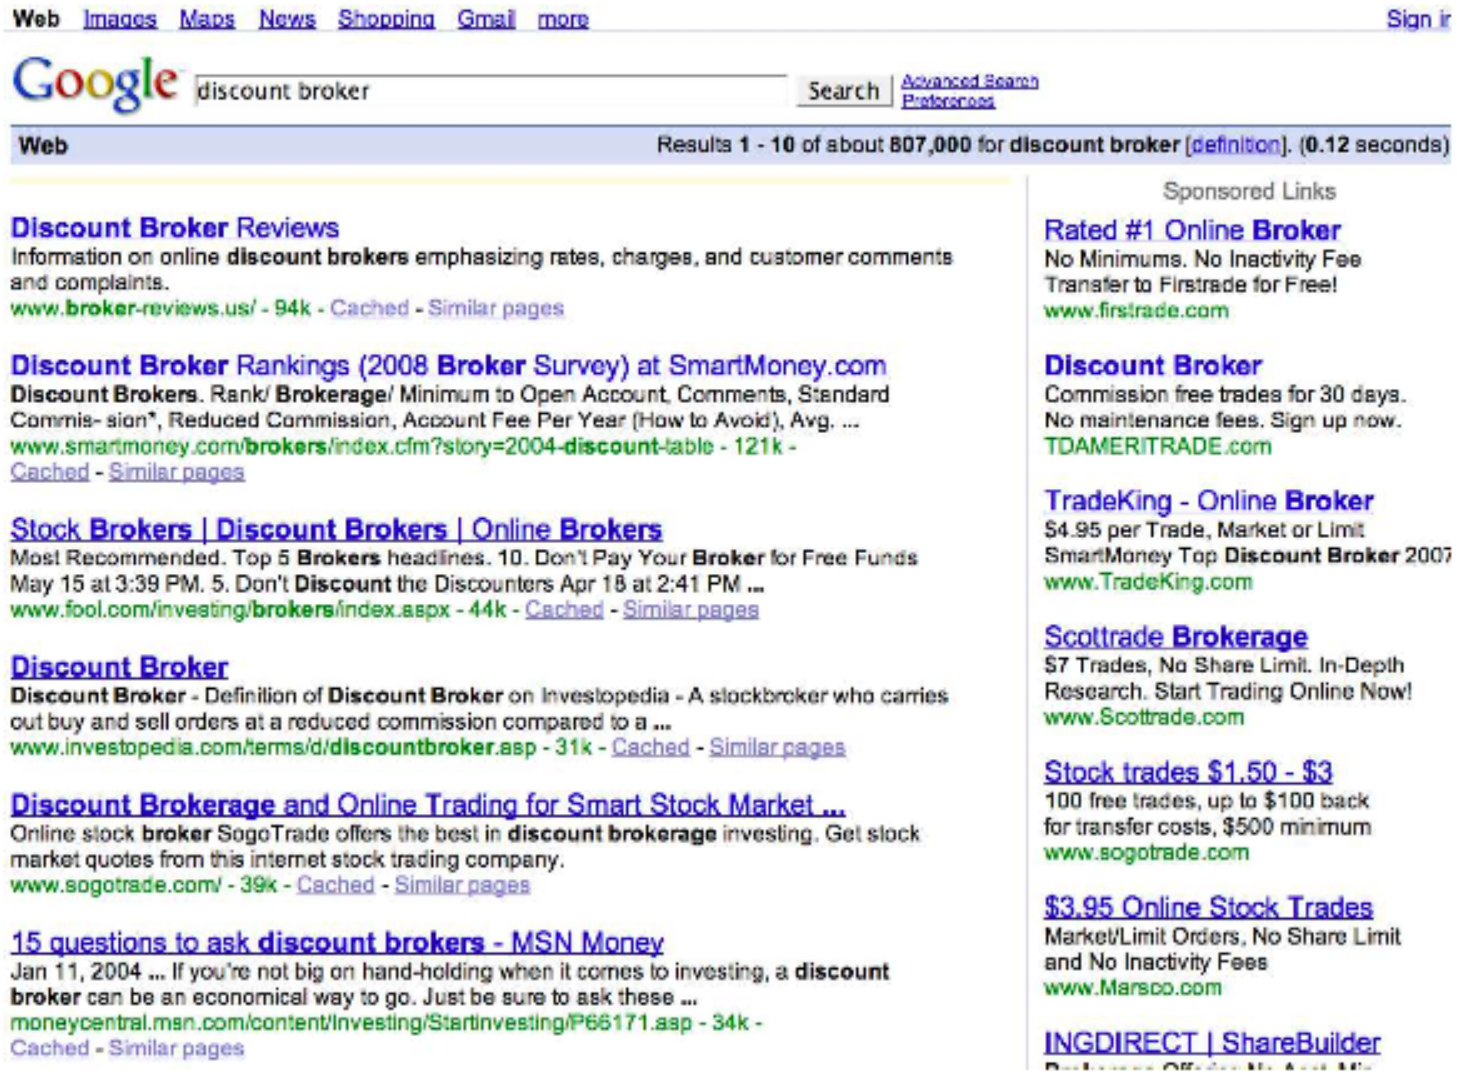
- SogoTrade 出现在搜索结果中
- SogoTrade 出现在广告中
- 搜索引擎是不是把广告商的结果放在非广告商的结果之前?
- 所有的主流搜索引擎都否认这一点

广告是否会影响编辑的内容？

- 在报纸、电视上存在类似问题
- 报纸一般不会刊登针对其主要广告商的严厉指责性质的文章
- 在报纸和TV上，广告和编辑内容之间的界限往往变得很模糊
- 现在还不清楚搜索引擎广告是否和上面一样

- “软文”
- 微信公众号等新媒体

广告在右部如何排序？


Web Images Maps News Shopping Gmail more Sign in
Google discount broker Search Advanced Search Preferences
Web Results 1 - 10 of about 807,000 for discount broker [definition]. (0.12 seconds)
Discount Broker Reviews
Information on online discount brokers emphasizing rates, charges, and customer comments and complaints.
www.broker-reviews.us/ - 94k - Cached - Similar pages
Discount Broker Rankings (2008 Broker Survey) at SmartMoney.com
Discount Brokers. Rank/ Brokerage/ Minimum to Open Account, Comments, Standard Commis- sion*, Reduced Commission, Account Fee Per Year (How to Avoid), Avg. ...
www.smartmoney.com/brokers/index.cfm?story=2004-discount-table - 121k - Cached - Similar pages
Stock Brokers | Discount Brokers | Online Brokers
Most Recommended. Top 5 Brokers headlines. 10. Don't Pay Your Broker for Free Funds May 15 at 3:39 PM. 5. Don't Discount the Discounters Apr 18 at 2:41 PM ...
www.fool.com/investing/brokers/index.aspx - 44k - Cached - Similar pages
Discount Broker
Discount Broker - Definition of Discount Broker on Investopedia - A stockbroker who carries out buy and sell orders at a reduced commission compared to a ...
www.investopedia.com/terms/d/discountbroker.asp - 31k - Cached - Similar pages
Discount Brokerage and Online Trading for Smart Stock Market ...
Online stock broker SogoTrade offers the best in discount brokerage investing. Get stock market quotes from this internet stock trading company.
www.sogotrade.com/ - 39k - Cached - Similar pages
15 questions to ask discount brokers - MSN Money
Jan 11, 2004 ... If you're not big on hand-holding when it comes to investing, a discount broker can be an economical way to go. Just be sure to ask these ...
moneycentral.msn.com/content/Investing/Startinvesting/P66171.asp - 34k - Cached - Similar pages
Sponsored Links
Rated #1 Online Broker
No Minimums. No Inactivity Fee
Transfer to Firstrade for Free!
www.firstrade.com
Discount Broker
Commission free trades for 30 days.
No maintenance fees. Sign up now.
TDAMERITRADE.com
TradeKing - Online Broker
$4.95 per Trade, Market or Limit
SmartMoney Top Discount Broker 2007
www.TradeKing.com
Scottrade Brokerage
$7 Trades, No Share Limit. In-Depth Research. Start Trading Online Now!
www.Scottrade.com
Stock trades $1.50 - $3
100 free trades, up to $100 back for transfer costs, $500 minimum
www.sogotrade.com
$3.95 Online Stock Trades
Market/Limit Orders, No Share Limit and No Inactivity Fees
www.Marsco.com
INGDIRECT | ShareBuilder

如何对广告排序？

- 广告商对关键词竞标 – 拍卖方式
  - 拍卖系统公开，任何人都可以参与关键词竞标
  - 广告商仅在用户点击广告商才真正付费
- 拍卖机制如何确定某条广告的排序以及该广告的支付价格?
- 基本思路是次高价拍卖(second price auction)原则
- 搜索引擎中最重要的研究领域之一---计算广告学
  - 对每条广告压榨出一分钱也就意味着为搜索引擎公司带来上亿额外收益

如何对广告排序？

- **简单的方法:**
  - **按照类似Goto的方式，即按照投标价格排序**
  - **不好的方法: 可能会被滥用**
  - **例如：query [house price?]**
  - **我们并不想得到相关性上无关的广告**
- 替代方法
  - **按照投标价格和相关性排序**
- **相关度度量的关键指标：点击率**(CTR, click through rate)
  - Click through rate = CTR = clicks per impressions

如何对广告排序？

- **结果：无关的广告将得到很低的排名**
  - 即使在短期时间内降低了搜索引擎的收益
  - **希望：如果用户能通过系统获得有价值的信息，那么系统的总体接受程度和整体收益将最大化**
- 其他排序因子：**位置、一天内的访问时间、着陆页(landing page)的质量和读取速度**
- **最主要的排序因子：查询**

Google AdsWords 的例子

Google次高竞标价格拍卖机制

advertiser	bid	CTR	ad rank	rank	paid
A	$4.00	0.01	0.04	4	(minimum)
B	$3.00	0.03	0.09	2	$2.68
C	$2.00	0.06	0.12	1	$1.51
D	$1.00	0.08	0.08	3	$0.51

- bid: 每个广告商为每次点击给出的最大投标价格
- CTR: **点击率，即一旦被显示后被点击的比率。**CTR是一种相关性度量指标
- ad rank: bid × CTR: 这种做法可以在 (i) 广告商愿意支付的价钱 (ii) 广告的相关度高低 之间进行平衡
- rank: **拍卖中的排名**
- paid: **广告商的次高竞标价格**

Google次高竞标价格拍卖机制

advertiser	bid	CTR	ad rank	rank	paid
A	$4.00	0.01	0.04	4	(minimum)
B	$3.00	0.03	0.09	2	$2.68
C	$2.00	0.06	0.12	1	$1.51
D	$1.00	0.08	0.08	3	$0.51

次高竞标价格拍卖： **广告商支付其维持在拍卖中排名所必须的价钱(加上一分钱) (用它的下一名计算其支付价格)**

$price_1 \times CTR_1 = bid_2 \times CTR_2$ (使得排名$rank_1$=$rank_2$)

$price_1 = bid_2 \times CTR_2 / CTR_1$

$p_1 = bid_2 \times CTR_2/CTR_1 = 3.00 \times 0.03/0.06 = 1.50$
$p_2 = bid_3 \times CTR_3/CTR_2 = 1.00 \times 0.08/0.03 = 2.67$
$p_3 = bid_4 \times CTR_4/CTR_3 = 4.00 \times 0.01/0.08 = 0.50$

具有高投标价格的关键词

参考http://www.cwire.org/highest-paying-search-terms/

$69.1 mesothelioma treatment options

$65.9 **personal injury lawyer** michigan

$62.6 **student loans** consolidation

$61.4 **car accident attorney** los angeles

$59.4 **online car insurance** quotes

$59.4 arizona **dui lawyer**（dui: driving under the influence ）

具有高投标价格的关键词

参考http://www.cwire.org/highest-paying-search-terms/

$46.4 asbestos cancer

$40.1 home equity line of credit

$39.8 **life insurance** quotes

$39.2 refinancing

$38.7 equity line of credit

$38.0 lasik **eye surgery** new york city

$37.0 2nd mortgage

$35.9 free car insurance quote

具有高投标价格的关键词

- **中文领域**
  - **金融**
  - **房地产**
  - **医疗等**
    - **莆田医院**
    - **魏则西事件**

搜索广告: 三赢？

- 每次用户点击广告，搜索引擎公司将会获得收益
- 用户只会点击其感兴趣的广告
  - 搜索引擎会对误导性和不相关的广告进行惩罚
  - 于是，用户在点击广告后往往会感到满意
- 广告商通过广告能够在物有所值的情况下找到新的客户

并非三赢: 关键词套现(Keyword arbitrage)

- 比如从Google买一个关键词
- 然后将**流量导向一个第三方页面**，该页面对应机构付的钱将比你付给Google的多得多
  - **比如，重定向到一个满是广告的页面**
- 该页面对于搜索用户来说基本没意义
- 广告作弊者一直在钻营想招
- 搜索引擎必须要花时间对付他们

并非三赢: 商标侵权

- 例子: geico (美国政府雇员保险公司，是美国第四大私人客户汽车保险公司)
  - 2005年的部分时间内: 搜索词项 “geico” 在Google上可以买到
  - Geico 在美国控告Google侵权
- Louis Vuitton(LV) 在欧洲控告Google侵权
  - 参考 http://google.com/tm complaint.html
- **如果采用商标做关键词，那么用户可能被误导到一个页面，该页面实际和用户期望购买的品牌产品无关**

提纲

1. 上一讲回顾
2. 互联网发展趋势
3. 互联网广告
4. 重复检测

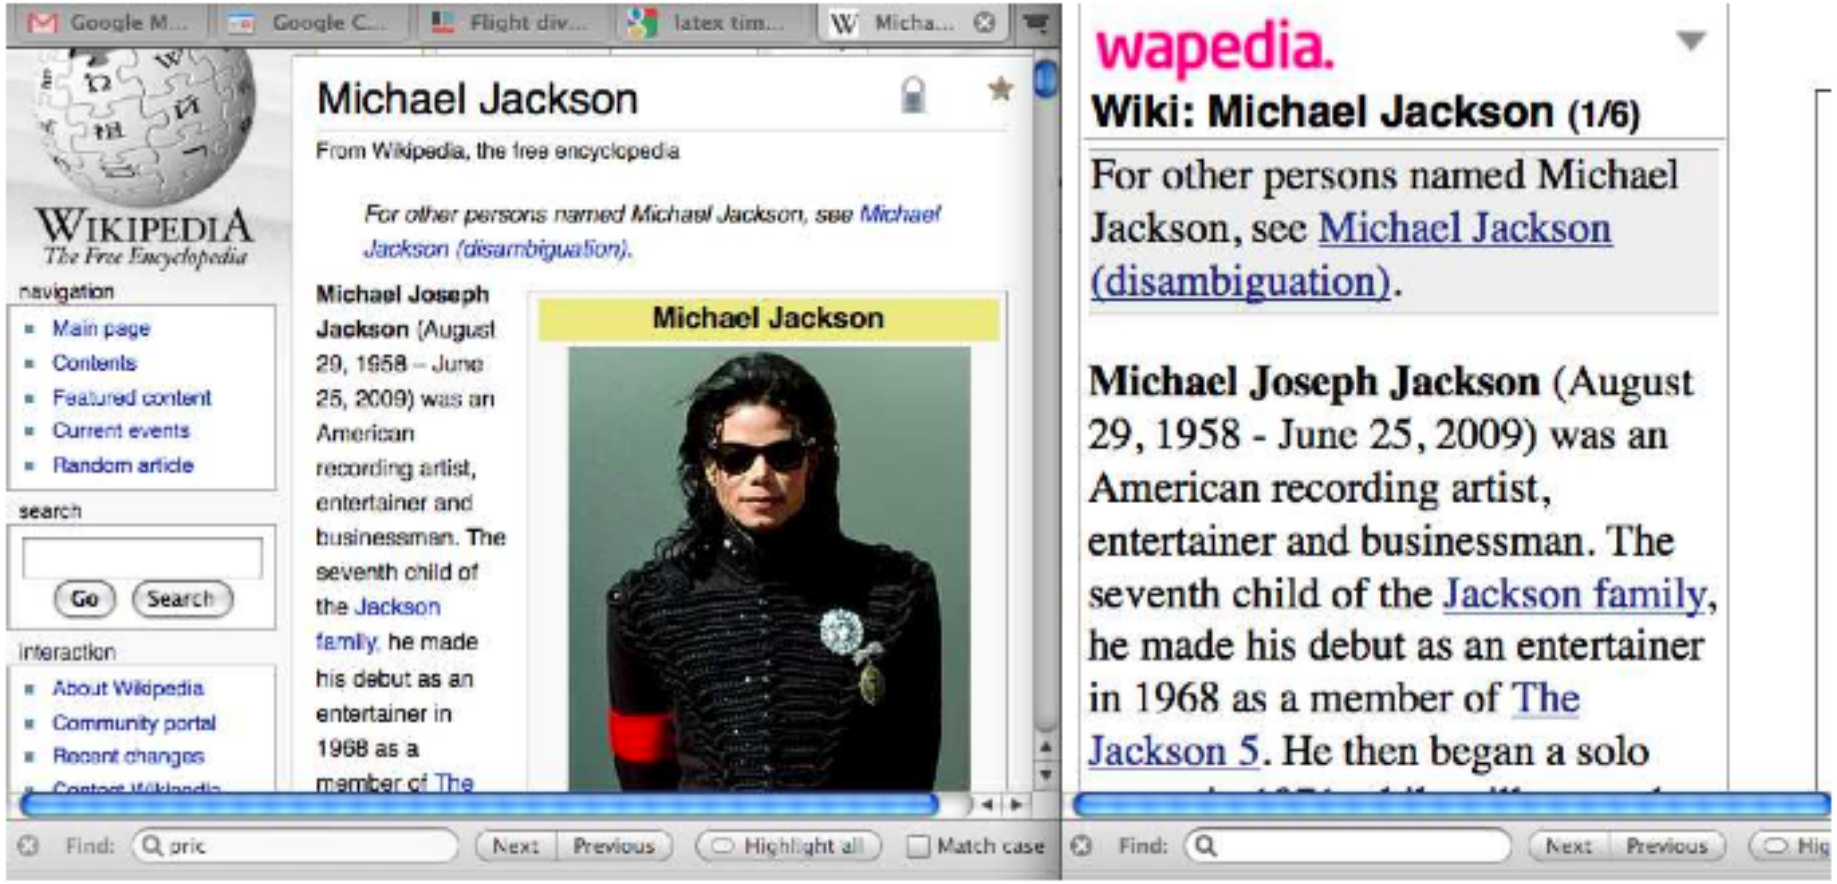
重复检测

- Web上充斥重复内容
- 相对其它文档集合，Web上的重复内容更多
- **完全重复(Exact duplicate)**
  - **易剔除，比如采用哈希/指纹的方法**
- **近似重复(Near-duplicate)**
  - **Web上存在大量近似重复**
  - **很难剔除**

重复检测

- 对用户而言，如果搜索结果中存在不少几乎相同的页面，那么体验非常不好
- **边缘相关度**(Marginal relevance)为0：**如果一篇高度相关的文档出现在另一篇高度近似的文档之后，那么该文档变得不相关(冗余)**
- 必须要**去除这些近似重复**

近似重复的例子


Michael Jackson
From Wikipedia, the free encyclopedia
For other persons named Michael Jackson, see Michael Jackson (disambiguation).
Michael Joseph Jackson (August 29, 1958 – June 25, 2009) was an American recording artist, entertainer and businessman. The seventh child of the Jackson family, he made his debut as an entertainer in 1968 as a member of The
Michael Jackson
WIKIPEDIA
The Free Encyclopedia
navigation
Main page
Contents
Featured content
Current events
Random article
search
Go
Search
interaction
About Wikipedia
Community portal
Recent changes
wapedia.
Wiki: Michael Jackson (1/6)
For other persons named Michael Jackson, see Michael Jackson (disambiguation).
Michael Joseph Jackson (August 29, 1958 - June 25, 2009) was an American recording artist, entertainer and businessman. The seventh child of the Jackson family, he made his debut as an entertainer in 1968 as a member of The Jackson 5. He then began a solo

近似重复的检测

- **采用编辑距离指标计算页面之间的相似度**
- **需要说明的是，我们希望检测那些“语法”(syntactic)上而不是“语义”(semantic)上相似的页面**
  - 页面的**语义相似度**(即内容语义之间的相似度)非常难以计算
- 也就是说，我们并不考虑那些**内容意义上相似但是表达方式不同的近似重复**

近似重复的检测

- **引入一个相似度阈值θ 来判定“两个页面之间是否近似重复”**
- **比如，如果两篇文档的相似度 > 阈值θ = 80%，那么认为两篇文档近似重复**

将每篇文档表示成一个shingle集合

- 可以通过指纹(fingerprinting)算法将shingle（搭叠）映射到 1..2^m (例如 m = 64)之间
- 接下来用s_k 来代表某个shingle映射到1..2^m之间的一个数
- 两个文档的相似度定义为它们的shingle集合的Jaccard距离

将每篇文档表示成一个shingle集合

- 每个shingle（搭叠） 是一个基于词语的n-gram
- 一个n-gram代表由n个字符组成的序列
- 通配符查询
- 使用shingle来计算文档之间的语法相似度
- 比如，对于n = 3，那么文档 “a rose is a rose is a rose” 就可以表示成shingle的集合：
  - { a-rose-is, rose-is-a, is-a-rose }

Jaccard系数

- **常用的计算两个集合重合度的方法**
- **令 *A* 和 *B* 分别表示两个集合**
- **Jaccard系数**

$$JACCARD(A,\ B) = \frac{|A \cap B|}{|A \cup B|} (A \neq \emptyset\ or\ B \neq \emptyset)$$

- **JACCARD(*A*,*A*) = 1**
- **JACCARD(*A*,*B*) = 0 if *A* ∩ *B* = 0**
- **并不要求*A* 和*B* 的大小一样**

Jaccard距离

- **令 A 和 B 分别表示两个集合**
- **Jaccard距离**

$$d_j(A,\ \mathrm{B}) = 1 - \frac{|A \cap B|}{|A \cup B|} (\mathrm{A} \neq \emptyset\ or\ \mathrm{B} \neq \emptyset)$$

- **Jaccard距离取值在[0,1]之间**
- **推论：Jaccard距离+Jaccard系数=1**

Jaccard距离计算的例子

- 3篇文档：

  d_1：“Jack London traveled to Oakland”

  d_2：“Jack London traveled to the city of Oakland”

  d_3：“Jack traveled from Oakland to London”

- **基于2-gram的shingle表示，计算文档之间的Jaccard系数、Jaccard距离**

基于2-gram的shingle表示

d_1: "Jack London traveled to Oakland"

d_2: "Jack London traveled to the city of Oakland"

d_3: "Jack traveled from Oakland to London"

d_1	d_2	d_3
Jack London	Jack London	Jack traveled
London traveled	London traveled	traveled from
traveled to	traveled to	from Oakland
to Oakland	to the	Oakland to
	the city	to London
	city of	
	of Oakland	

$|d_1 \cap d_2|$ $|d_1 \cap d_3|$ $|d_2 \cap d_3|$

$|d_1 \cup d_2|$ $|d_1 \cup d_3|$ $|d_2 \cup d_3|$

Jaccard距离计算的例子

- **解：**
  - **Jaccard系数**
    - $J(d_1, d_2) = 3/8 = 0.375$
    - $J(d_1, d_3) = 0$
    - $J(d_2, d_3) = 0$
  - **Jaccard距离**
    - $d_j(d_1, d_2) = 1 - J(d_1, d_2) = 1 - 3/8 = 5/8 = 0.625$
    - $d_j(d_1, d_3) = 1 - J(d_1, d_3) = 1$
    - $d_j(d_2, d_3) = 1 - J(d_2, d_3) = 1$
  - **Jaccard距离对差异十分敏感**

将文档表示成梗概(sketch)

- 每篇文档的shingle的个数非常大
- 为提高效率，使用**文档的梗概**来表示文档，它**由文档的shingle集合中精巧挑选出的子集构成**
- 比如，梗概中shingle的数目为 $n = 200$ . . .
- . . .通过一系列置换$\pi_1 \ldots \pi_{200}$来定义
- 每个置换 π_i 都是1..2^m上的**随机置换**
- **成功的置换比例就等于Jaccard距离**

实现

- 使用**哈希函数**来实现高效的置换:

  $h_i : \{1..2^m\} \rightarrow \{1..2^m\}$

- 以**任意顺序扫描**两个集合并集中所有shingle s_k
- 对每个哈希函数 h_i 及文档d_1, d_2, . . .: 在某个固定存储位置中**保留当前的最小值**
- 如果h_i (s_k) 小于当前的最小值，那么对固定存储位置上的值进行更新

Shingling技术概要

输入： N篇文档

- 选择用于生成shingle的n-gram的大小，例如 $n = 5$
- 选择200个随机置换，每个置换可以通过**哈希函数**表示
- 计算 N个梗概值: 得到一个200 × N的矩阵，其中每一行对应一个置换，每一列对应一个文档

- **计算** $\frac{\mathrm{N} \times (N-1)}{2}$ **个两两文档之间的相似度**

高效的近似重复检测

- 估计两篇文档Jaccard距离的非常**高效算法**
- 但是如果Web网页数目为N，那么仍然需要估计$O(N^2)$个相似度，仍然无法处理
- 解决办法
  - **位置敏感哈希**(locality sensitive hashing，简称LSH)
  - **排序** (Henzinger 2006)

本讲小结

- **互联网发展趋势分析**
- **互联网广告**
- **重复检测**

参考资料

- **《信息检索导论》第 19 章**
- **http://ifnlp.org/ir**
- **Stanford 计算广告学课程**

  http://www.stanford.edu/class/msande239/