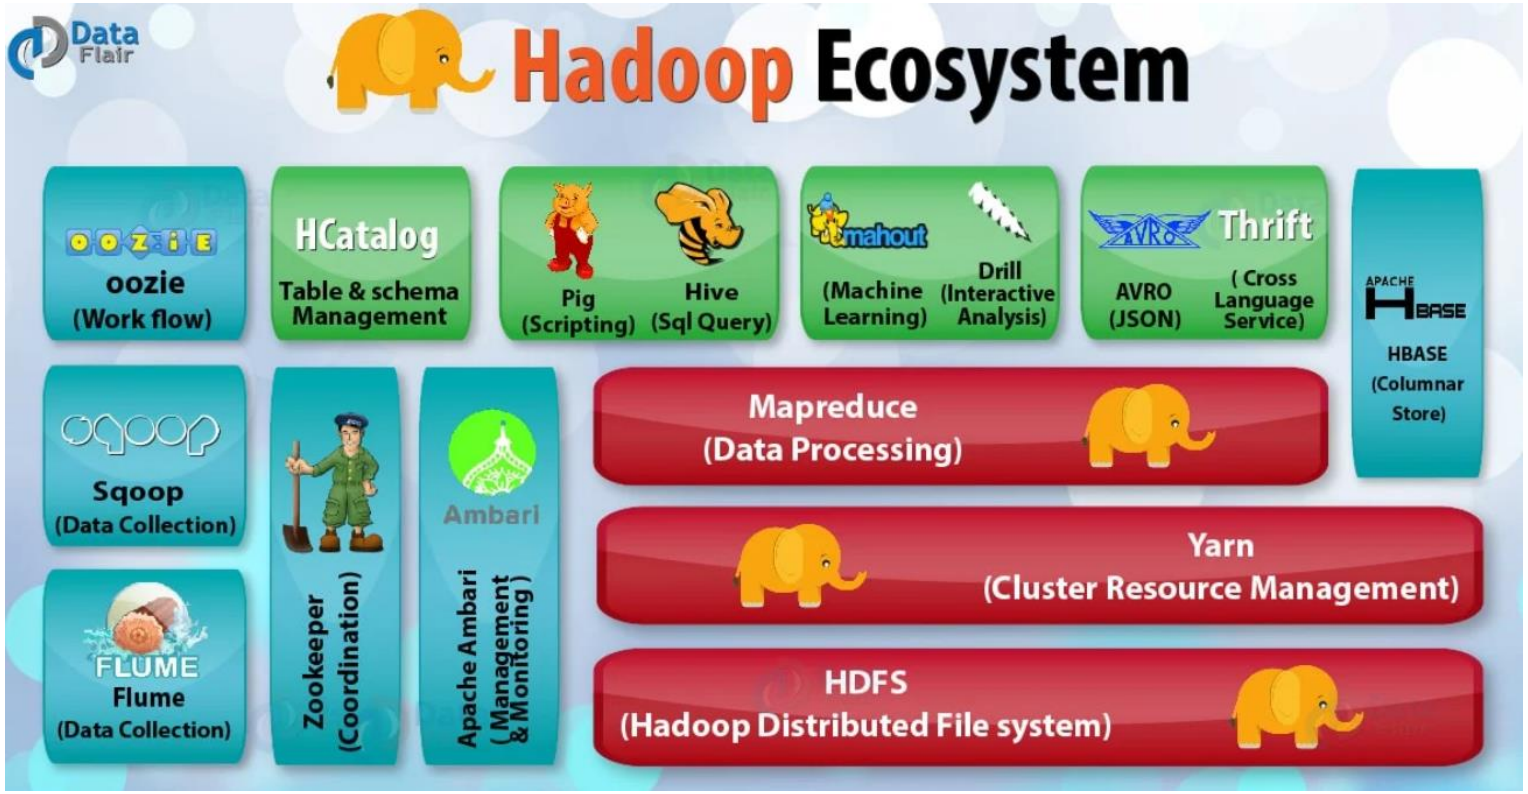
Spark & Hadoop



Apache Hadoop

❑ Hadoop

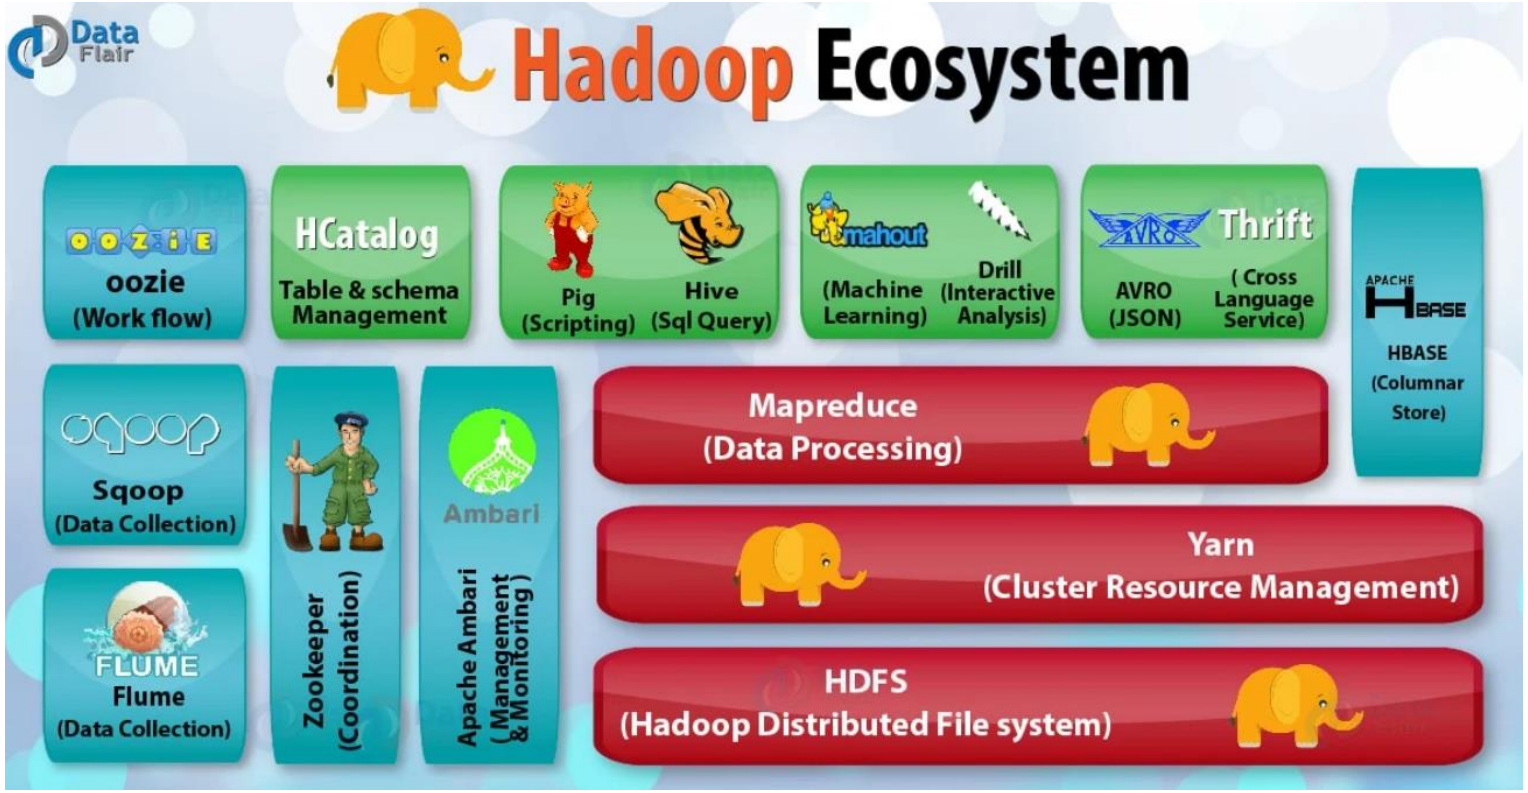
➢ Apache Hadoop 是一个以分布式方式处理大型数据集的平台。该框架使用 MapReduce 将数据拆分为块，并将块分配给集群中的节点。然后，**MapReduce** 在每个节点上并行处理数据以产生唯一的输出。



Apache Hadoop

❑ Hadoop

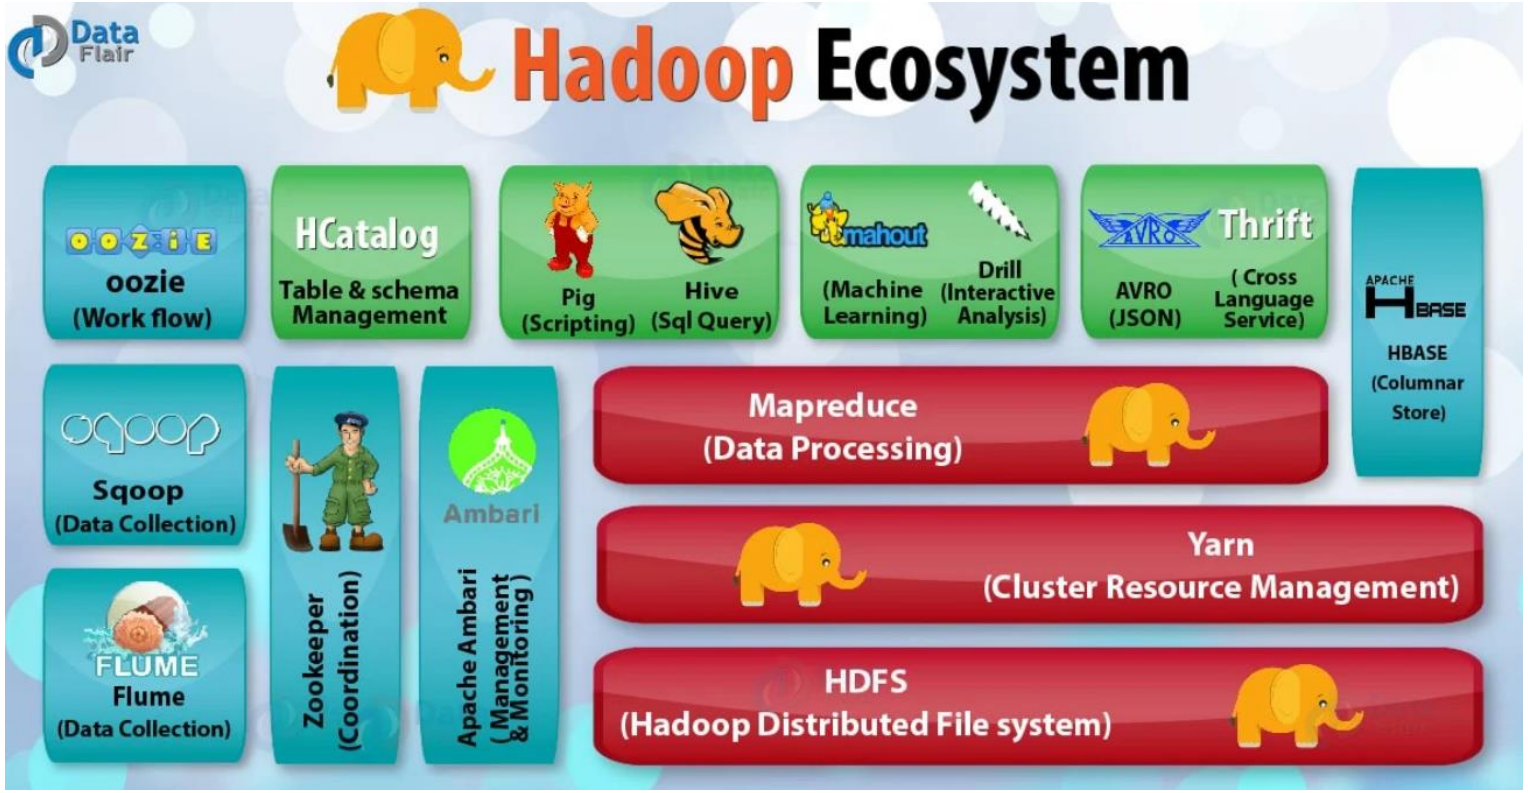
➢ 集群中的每台机器都存储和处理数据。 Hadoop 使用 HDFS 将数据存储到磁盘。该软件提供无缝的可扩展性选项。你可以从一台机器开始，然后扩展到数千台，添加任何类型的企业或商品硬件。



Apache Hadoop

❑ Hadoop

➢ Hadoop 生态系统具有高度容错能力。 Hadoop不依赖硬件来实现高可用性。 Hadoop 的核心是为了查找应用程序层的故障。通过跨集群复制数据，当某个硬件发生故障时，该框架可以从另一个位置构建缺失的部分。



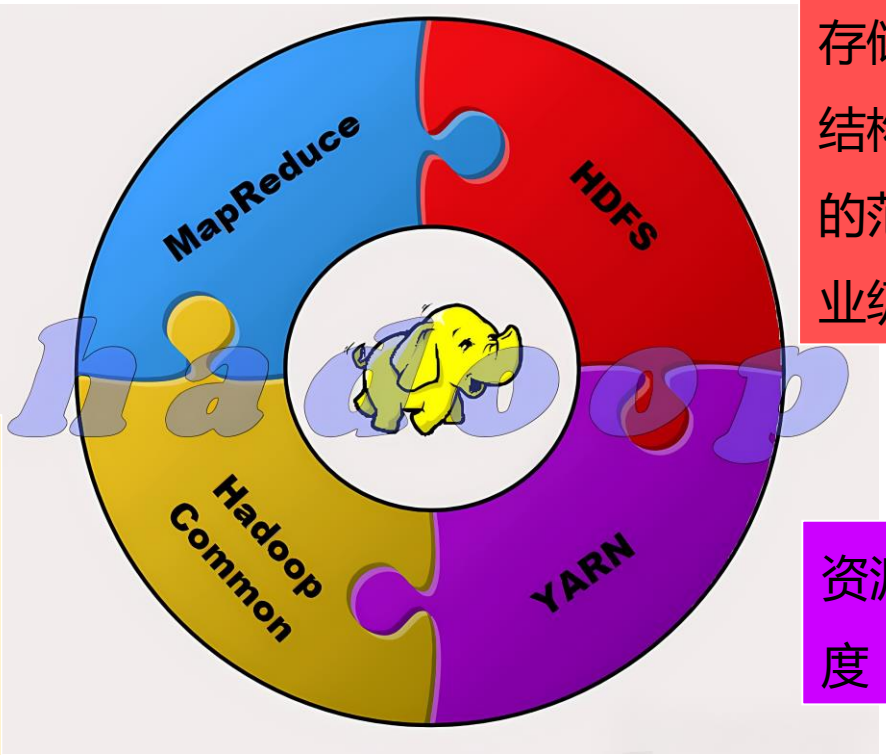
Apache Hadoop

❑ Hadoop

➢ Apache Hadoop 项目由四个主要模块组成：

Hadoop 生态系统的处理组件。它将来自 HDFS 的数据片段分配给集群中单独的映射任务。 MapReduce 并行处理这些块，将这些块组合成所需的结果。

HDFS——Hadoop 分布式文件系统。这是管理 Hadoop 集群中大量数据存储的文件系统。 HDFS 可以处理结构化和非结构化数据。存储硬件的范围可以从任何消费级 HDD 到企业级驱动器。



其他模块所依赖的一组公共库和实用程序。该模块的另一个名称是 Hadoop core，因为它为所有其他 Hadoop 组件提供支持。

资源调度，负责计算资源和作业调度

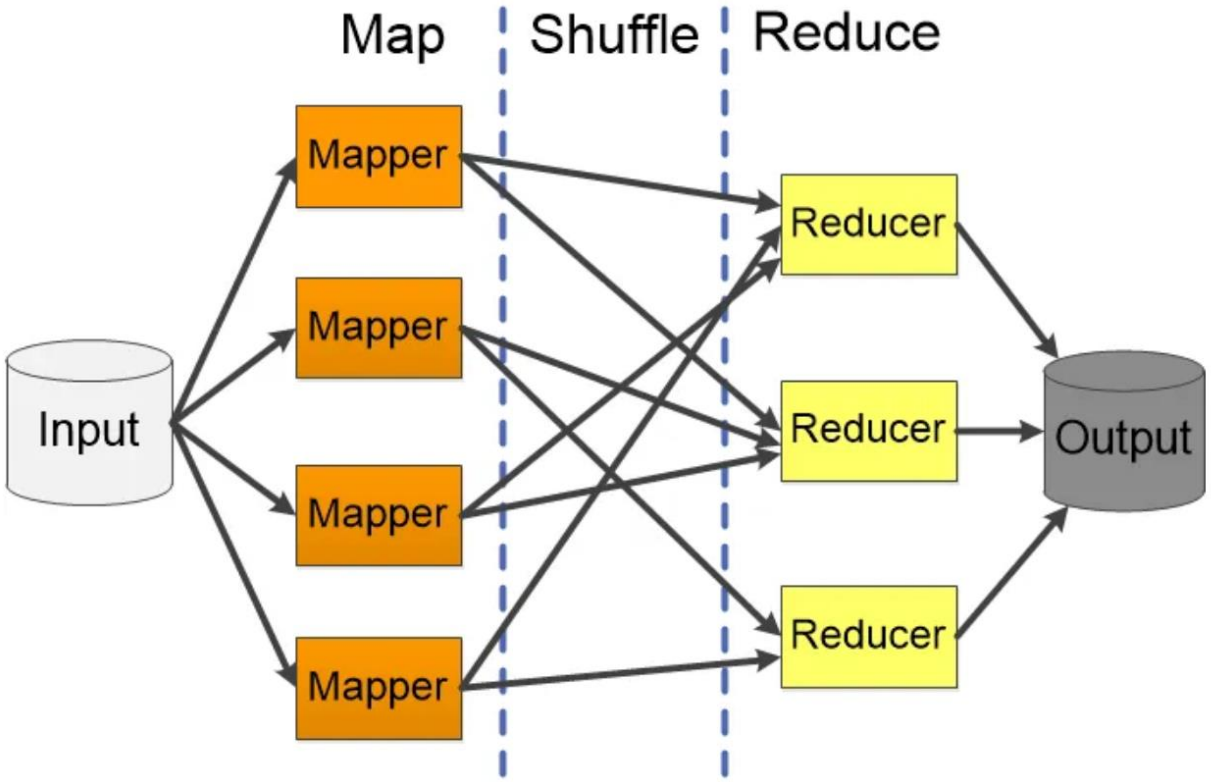
Apache Hadoop

❑ Hadoop

➢ MapReduce

■ 三个阶段：Map阶段，Shuffle阶段和Reduce阶段

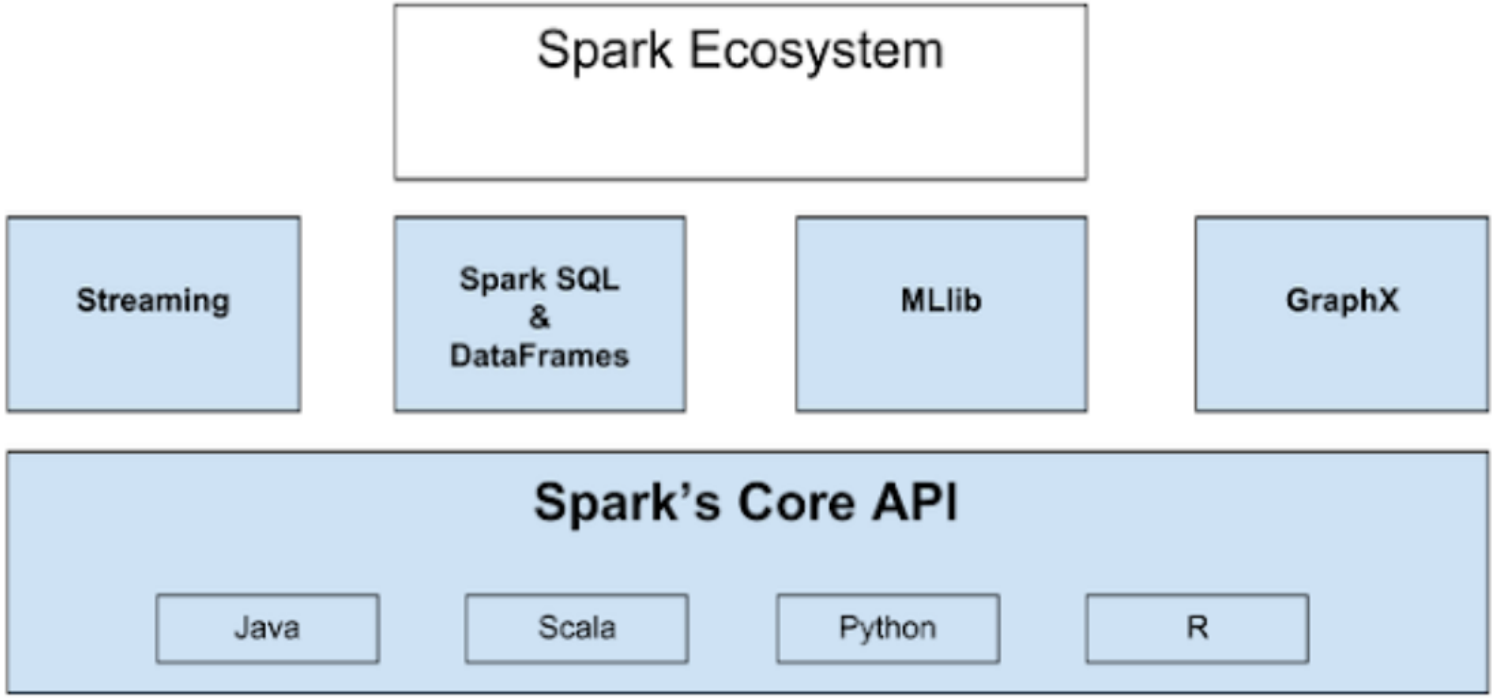
- 在Map阶段，数据被分成更小的块，并在分布式计算环境中并行处理。例如，获取日志文件并将其映射到要计数的日志类型的键值存储。
- Shuffle 阶段重新组织映射的数据，以便将相似的术语放在一起。就像采用日志类型并将所有相同的日志类型分组到一个部分中一样。
- Reduce 阶段聚合并组合 Shuffle 阶段的结果，以生成最终输出。就像对给定日志类型的所有计数求和一样。



Apache Spark

❑ Spark

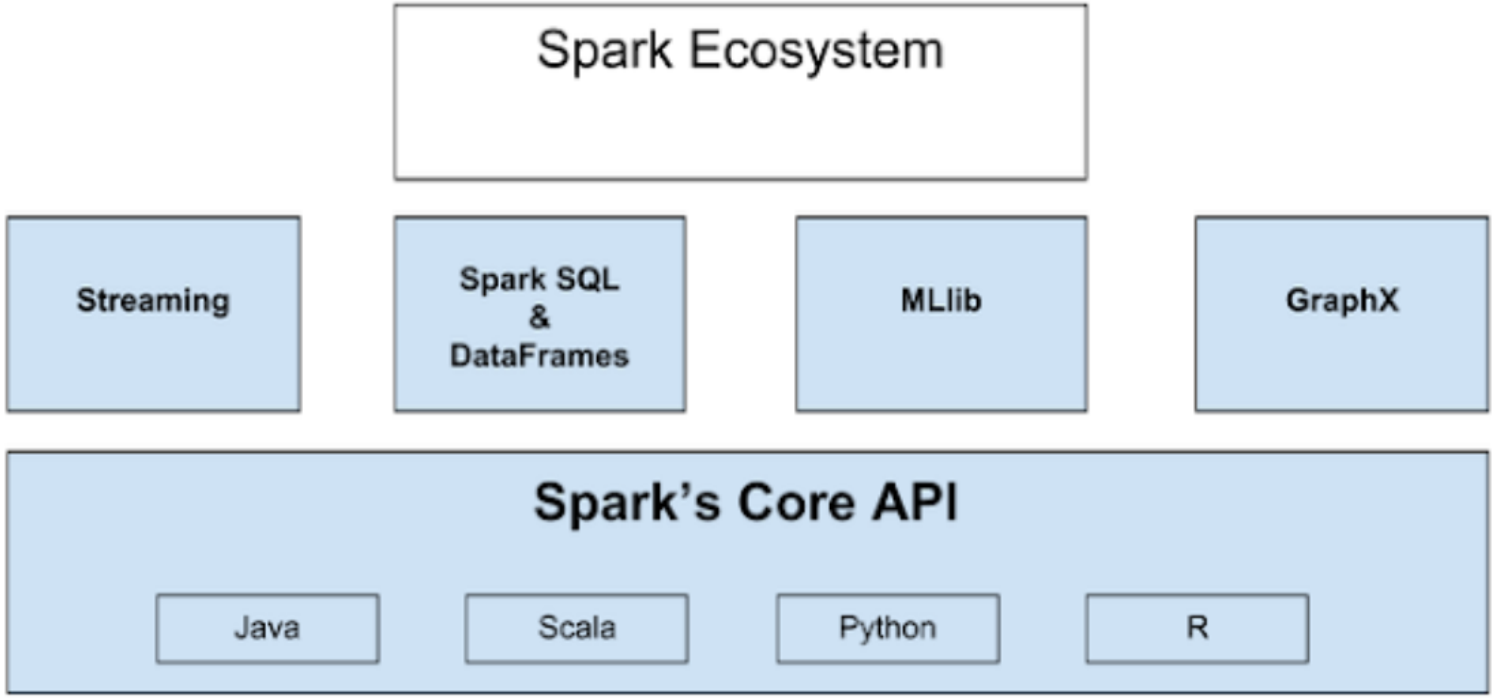
➢ Apache Spark 是一个开源工具。该框架可以以独立模式运行，也可以在云或集群管理器（例如 Apache Mesos）和其他平台上运行。它专为实现快速性能而设计，并使用 RAM 来缓存和处理数据。



Apache Spark

❑ Spark

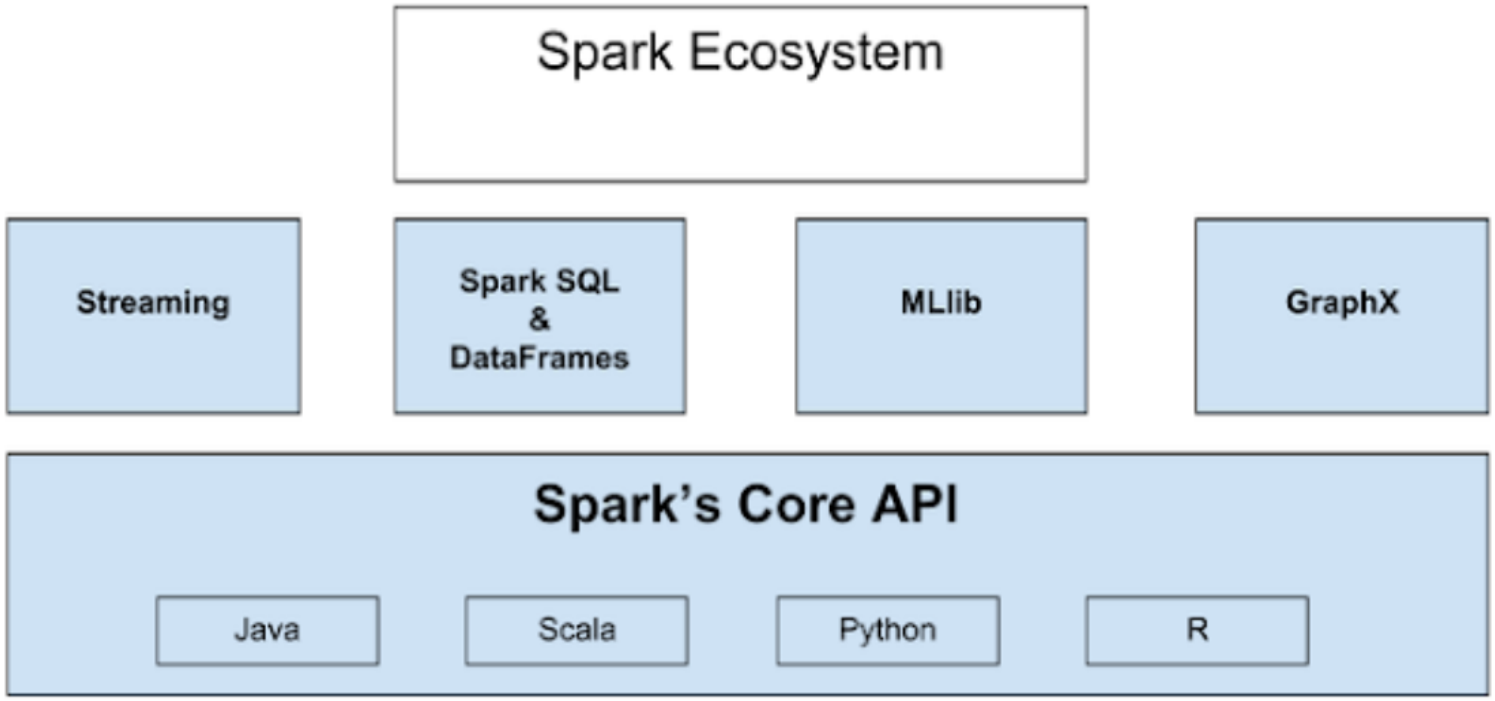
- Spark 执行不同类型的大数据工作负载。这包括类似 MapReduce 的批处理，以及实时流处理、机器学习、图形计算和交互式查询。凭借易于使用的高级 API，Spark 可以与许多不同的库集成，包括 PyTorch 和 TensorFlow。



Apache Spark

❑ Spark

➢ Spark 引擎的创建是为了提高 MapReduce 的效率并保持其优势。尽管 Spark 没有文件系统，但它可以访问许多不同存储解决方案上的数据。 **Spark 使用的数据结构称为弹性分布式数据集（RDD）**



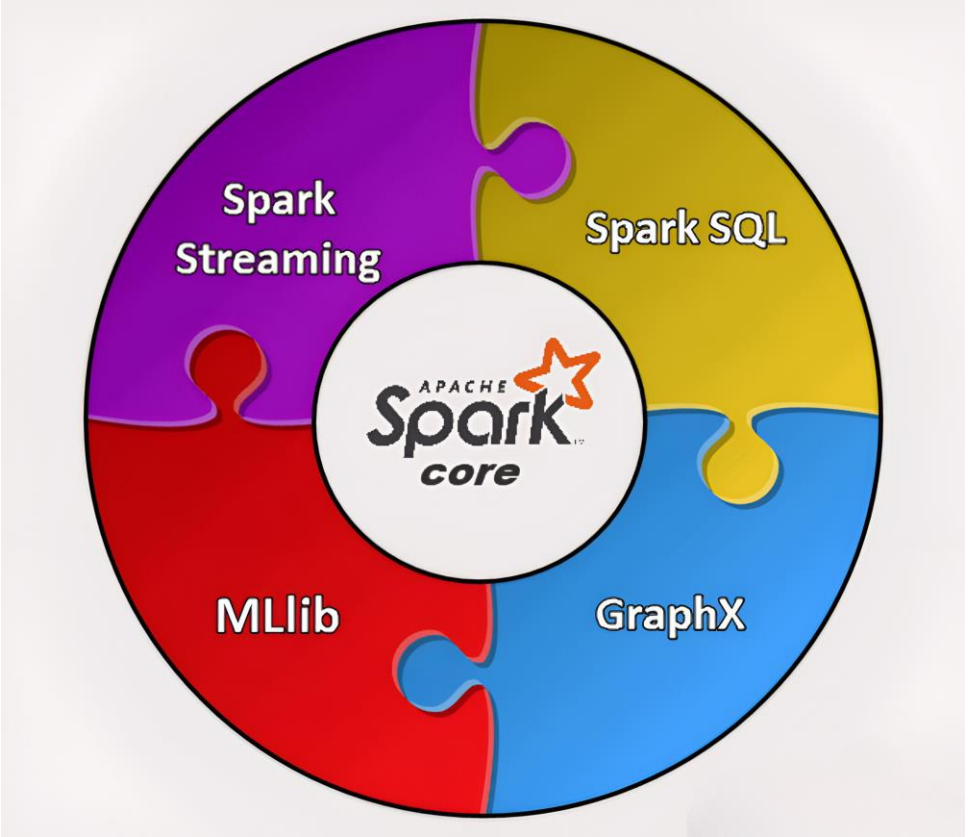
Apache Spark

❑ Spark

➢ Apache Spark 有五个主要组件

Apache Spark core：整个项目的基础。Spark Core负责调度、任务派发、输入输出操作、故障恢复等必要的功能，其他功能都构建在它之上。

Spark Streaming: 该组件可以处理实时数据流。数据可以来自许多不同的来源，包括 Kafka、Kinesis、Flume 等



Spark SQL: Spark 使用此组件来收集有关结构化数据以及数据处理方式的信息。

MIlib: 该库由许多机器学习算法组成。 MLlib 的目标是可扩展性并使机器学习更容易实现

GraphX一组用于促进图形分析任务的 API

Hadoop vs Spark

	Hadoop	Spark
Performance	Slower performance, uses disks for storage and depends on disk read and write speed.	Fast in-memory performance with reduced disk reading and writing operations.
Cost	An open-source platform, less expensive to run. Uses affordable consumer hardware. Easier to find trained Hadoop professionals.	An open-source platform, but relies on memory for computation, which considerably increases running costs.
Data Processing	Best for batch processing. Uses MapReduce to split a large dataset across a cluster for parallel analysis.	Suitable for iterative and live-stream data analysis. Works with RDDs and DAGs to run operations.
Fault Tolerance	A highly fault-tolerant system. Replicates the data across the nodes and uses them in case of an issue.	Tracks RDD block creation process, and then it can rebuild a dataset when a partition fails. Spark can also use a DAG to rebuild data across nodes.
Scalability	Easily scalable by adding nodes and disks for storage. Supports tens of thousands of nodes without a known limit.	A bit more challenging to scale because it relies on RAM for computations. Supports thousands of nodes in a cluster
Security	Extremely secure. Supports LDAP, ACLs, Kerberos, SLAs, etc.	Not secure. By default, the security is turned off. Relies on integration with Hadoop to achieve the necessary security level.
Ease of Use and Language Support	More difficult to use with less supported languages. Uses Java or Python for MapReduce apps.	More user friendly. Allows interactive shell mode. APIs can be written in Java, Scala, R, Python, Spark SQL.
Machine Learning	Slower than Spark. Data fragments can be too large and create bottlenecks. Mahout is the main library.	Much faster with in-memory processing. Uses MLlib for computations.
Scheduling and Resource Management	Uses external solutions. YARN is the most common option for resource management. Oozie is available for workflow scheduling.	Has built-in tools for resource allocation, scheduling, and monitoring.

Hadoop vs Spark

❑ 性能上面

- 通过访问本地存储在 HDFS 上的数据，Hadoop 提高了整体性能。然而，它无法与 Spark 的内存处理相媲美。根据 Apache 的说法，使用 RAM 进行计算时，Spark 的速度似乎比使用 MapReduce 的 Hadoop 快 100 倍。
- Spark之所以如此霸主，主要原因是它不将中间数据读写到磁盘上，而是使用RAM。 Hadoop 将数据存储在许多不同的源上，然后使用 MapReduce 批量处理数据。

Hadoop vs Spark

❑ 成本

- 这两个平台都是开源且完全免费的。然而，需要考虑基础设施、维护和开发成本才能获得粗略的总成本 (TCO)
- 成本类别中最重要的因素是运行这些工具所需的底层硬件。由于Hadoop依赖于任何类型的磁盘存储来进行数据处理，因此运行它的成本相对较低。
- 另一方面，Spark 依赖内存计算来进行实时数据处理。因此，使用大量 RAM 来启动节点会大大增加 ownership 成本。

Hadoop vs Spark

❑ 运算

- 这两个框架以完全不同的方式处理数据。虽然带有MapReduce的Hadoop和带有RDD的Spark都是在分布式环境中处理数据，但是Hadoop更适合批处理。相比之下，Spark 的亮点在于实时处理。
- Hadoop 的目标是将数据存储在磁盘上，然后在分布式环境中批量并行分析数据。 MapReduce 不需要大量 RAM 来处理大量数据。 Hadoop 依赖日常硬件进行存储，最适合线性数据处理。
- Apache Spark 使用弹性分布式数据集 (RDD)。 RDD 是存储在集群中节点上的分区中的分布式元素集。 RDD 的大小通常太大，单个节点无法处理。因此，Spark 将 RDD 分区到最近的节点并并行执行操作。系统使用有向无环图 (DAG) 跟踪在 RDD 上执行的所有操作。
- 借助内存计算和高级 API，Spark 可以有效处理非结构化数据的实时流。此外，数据存储在预定义数量的分区中。一个节点可以根据需要拥有任意多个分区，但一个分区不能扩展到另一个节点。

Hadoop vs Spark

❑ 容错能力 -- 均有容错能力， 但方式不同

- Hadoop以容错作为其运行的基础。它在节点之间多次复制数据。如果出现问题，系统会通过从其他位置创建丢失的块来恢复工作。主节点跟踪所有从节点的状态。最后，如果从节点没有响应来自主节点的 ping，则主节点会将待处理的作业分配给另一个从节点。
- Spark使用RDD块来实现容错。系统跟踪不可变数据集的创建方式。然后，当出现问题时，它可以重新启动该进程。 Spark 可以通过使用工作流的 DAG 跟踪来重建集群中的数据。这种数据结构使 Spark 能够处理分布式数据处理生态系统中的故障。

Hadoop vs Spark

❑ 可扩展性

- Hadoop 使用 HDFS 来处理大数据。当数据量快速增长时，Hadoop可以快速扩展以满足需求。由于Spark没有自己的文件系统，当数据太大而无法处理时，它必须依赖HDFS。
- 通过向网络添加更多服务器，集群可以轻松扩展和提高计算能力。因此，两个框架中的节点数量都可以达到数千个。对于每个集群可以添加的服务器数量以及可以处理的数据量没有严格的限制。
- 一些已确认的数字包括 Spark 环境中的 8000 台机器，数据量达到 PB。说到 Hadoop 集群，它们可以容纳数万台机器和接近 1 EB 的数据。

Hadoop vs Spark

❑ 易于使用和语言支持

- Spark 可能是较新的框架，可用专家的数量不如 Hadoop，但众所周知，它更加用户友好。相比之下，Spark 提供了对本机语言 (Scala) 之外的多种语言的支持：Java、Python、R 和 Spark SQL。这使得开发人员可以使用他们喜欢的编程语言。
- Hadoop框架是基于Java的。编写 MapReduce 代码的两种主要语言是 Java 或 Python。 Hadoop 没有交互模式来帮助用户。不过，它与 Pig 和 Hive 工具集成，可以方便编写复杂的 MapReduce 程序。
- 除了支持多种语言的 API 之外，Spark 还以其交互模式在易用性方面获胜。您可以使用 Spark shell 与 Scala 或 Python 交互地分析数据。 shell 为查询提供即时反馈，这使得 Spark 比 Hadoop MapReduce 更易于使用。

Hadoop vs Spark

❑ 安全性

- Hadoop 使用多种身份验证和访问控制方法。最难实现的是 Kerberos 身份验证。如果 Kerberos 难以处理，Hadoop 还支持 Ranger、LDAP、ACL、节点间加密、HDFS 上的标准文件权限以及服务级别授权。
- 对于Spark，通过共享密钥或事件日志记录引入身份验证可以提高 Spark 的安全性。然而，这对于生产工作负载来说还不够。Spark 通过与 Hadoop 集成可以达到足够的安全级别。这样，Spark 就可以使用 Hadoop 和 HDFS 可用的所有方法。此外，当 Spark 在 YARN 上运行时，可以采用我们上面提到的其他身份验证方法。



Hadoop vs Spark

❑ 机器学习

- 机器学习是一个迭代过程，使用内存计算效果最佳。因此，Spark 被证明是该领域更快的解决方案。原因是 Hadoop MapReduce 将作业拆分为并行任务，这对于机器学习算法来说可能太大。此过程会在这些 Hadoop 应用程序中产生 I/O 性能问题。
- Mahout 库是 Hadoop 集群中主要的机器学习平台。 Mahout 依靠 MapReduce 来执行聚类、分类和推荐。 Samsara开始取代这个项目。
- Spark 附带一个默认的机器学习库 MLlib。该库执行迭代内存中 ML 计算。它包括执行回归、分类、持久性、管道构建、评估等的工具。
- 在基于 Hadoop 磁盘的环境中，带有 MLlib 的 Spark 比 Apache Mahout 快九倍。当您需要比 Hadoop 提供的更高效的结果时，Spark 是机器学习的更好选择。

Hadoop vs Spark

❑ 调度和资源管理

- Hadoop 没有内置的调度程序。它使用外部解决方案进行资源管理和调度。 YARN通过ResourceManager和NodeManager负责Hadoop集群中的资源管理。 Oozie 是可用于安排工作流程的工具之一。
- YARN 不处理单个应用程序的状态管理。它仅分配可用的处理能力。
- Hadoop MapReduce 与 CapacityScheduler 和 FairScheduler 等插件配合使用。这些调度程序可确保应用程序根据需要获得必要的资源，同时保持集群的效率。 FairScheduler 为应用程序提供必要的资源，同时跟踪所有应用程序最终获得相同的资源分配。
- Spark 内置了这些功能。 DAG 调度程序负责将算子划分为阶段。每个阶段都有DAG调度和Spark需要执行的多个任务。
- Spark Scheduler 和 Block Manager 在集群中执行作业和任务的调度、监控和资源分配。

Hadoop vs Spark

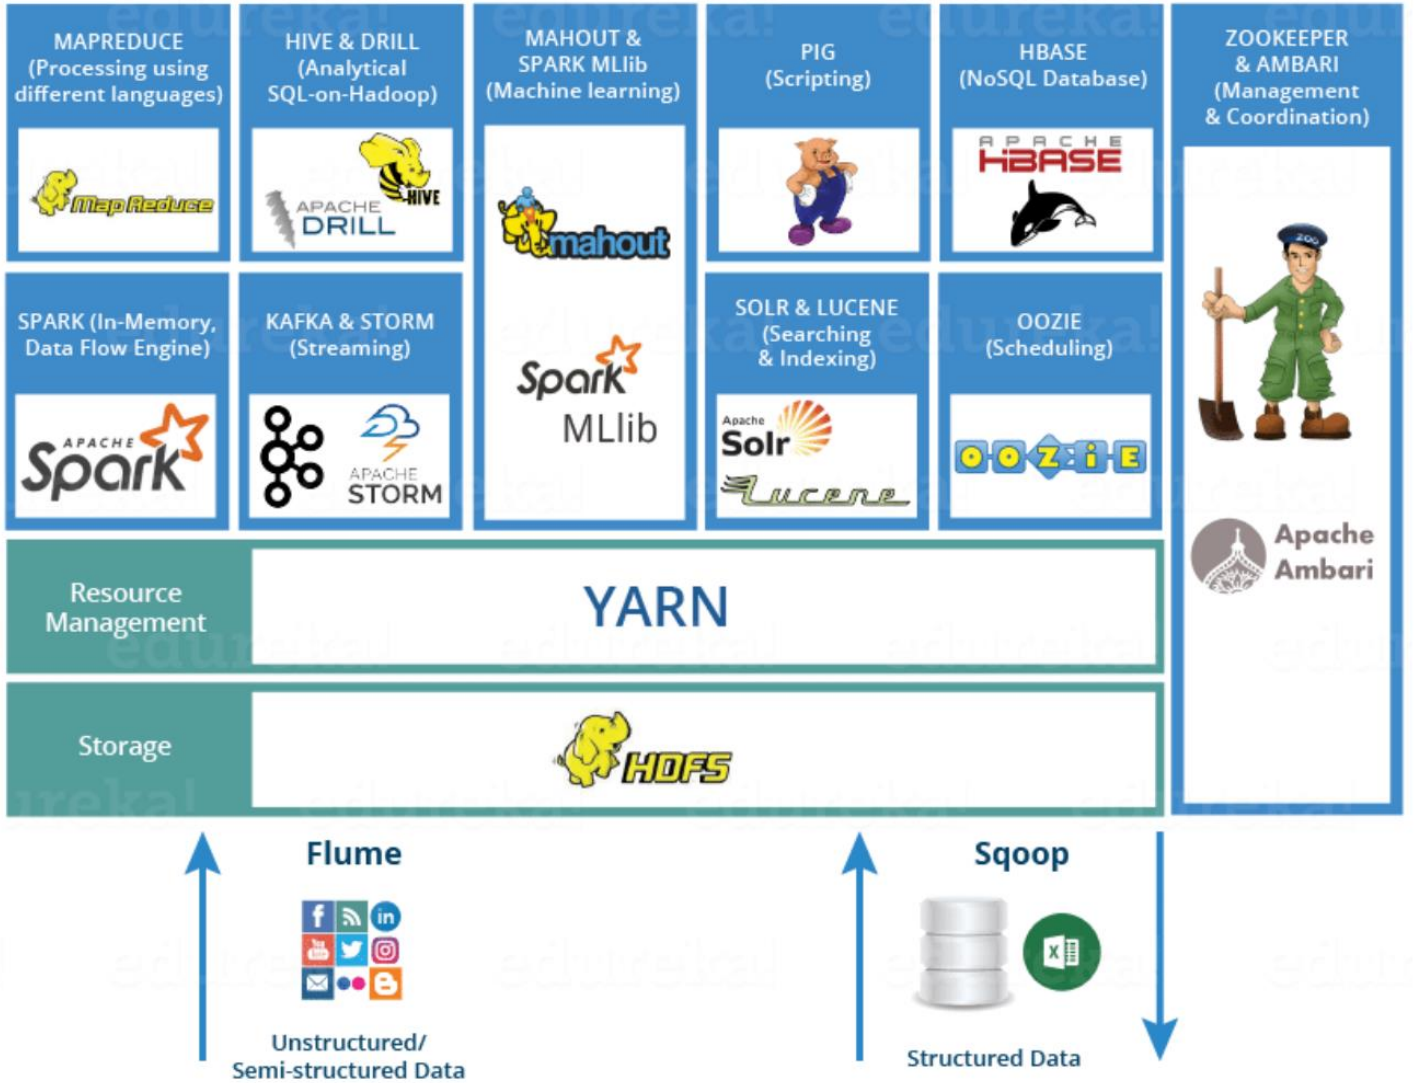
❑ Hadoop 和 Spark 是处理大数据的技术: 在管理和处理数据的方式上是非常不同的框架

- 在某些用例中，一个或另一个框架是更合理的选择。在大多数其他应用程序中，Hadoop 和 Spark 协同工作效果最佳。作为继任者，Spark 并不是要取代 Hadoop，而是要利用其功能创建一个新的、改进的生态系统。
- 通过将两者结合起来，Spark 可以利用它所缺少的功能，例如文件系统。 Hadoop 使用经济实惠的硬件存储大量数据，然后执行分析，而 Spark 则提供实时处理来处理传入数据。如果没有 Hadoop，业务应用程序可能会错过 Spark 无法处理的关键历史数据。
- 在这种协作环境中，Spark 还利用了 Hadoop 的安全性和资源管理优势。借助 YARN，Spark 集群和数据管理变得更加容易。你可以使用任何可用资源自动运行 Spark 工作负载。

Hadoop vs Spark

❑ **Hadoop 和 Spark 是处理大数据的技术: 在管理和处理数据的方式上是非常不同的框架**

- 这两个框架在大数据应用中都发挥着重要作用。虽然 Spark 因其速度和用户友好模式而成为首选平台，但某些用例需要运行 Hadoop。当需要分析大量数据时尤其如此。
- Spark 需要更大的维护预算，但也需要更少的硬件来执行与 Hadoop 相同的工作。应该记住，这两个框架各有优点，并且它们最好一起工作。



Hadoop vs Spark

❑ Spark

- Apache Spark 是MapReduce的增强版
- 尽管Spark相对于Hadoop而言具有较大优势，但Spark并不能完全替代Hadoop，Spark主要用于替代Hadoop中的MapReduce计算模型。存储依然可以使用HDFS，但是中间结果可以存放在内存中；调度可以使用Spark内置的，也可以使用更成熟的调度系统YARN等。