Spark DataFrame



Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 1. 创建 Spark Session

- 2. 加载数据（walmart_stock.csv），使用inferSchema

```
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use
setLogLevel(newLevel).
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 3. 查看数据

```
+----------+------------------+------------------+------------------+-
-----------------+--------+------------------+
|      Date|              Open|              High|               Low|
Close|  Volume|         Adj Close|
+----------+------------------+------------------+------------------+-
-----------------+--------+------------------+
|2012-01-03|         59.970001|         61.060001|         59.869999|
60.330002|12668800|52.619234999999996|
|2012-01-04|60.209998999999996|         60.349998|         59.470001|5
9.709998999999996| 9593300|         52.078475|
|2012-01-05|         59.349998|         59.619999|         58.369999|
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 3. 查看列名

```
['Date', 'Open', 'High', 'Low', 'Close', 'Volume', 'Adj Close']
```

- 4. 查看数据结构

```
root
 |-- Date: string (nullable = true)
 |-- Open: double (nullable = true)
 |-- High: double (nullable = true)
 |-- Low: double (nullable = true)
 |-- Close: double (nullable = true)
 |-- Volume: integer (nullable = true)
 |-- Adj Close: double (nullable = true)
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 5. 打印出前5行

```
Row(Date='2012-01-03', Open=59.970001, High=61.060001, Low=59.869999,
Close=60.330002, Volume=12668800, Adj Close=52.619234999999996)


Row(Date='2012-01-04', Open=60.209998999999996, High=60.349998, Low=5
9.470001, Close=59.709998999999996, Volume=9593300, Adj Close=52.07847
5)


Row(Date='2012-01-05', Open=59.349998, High=59.619999, Low=58.369999,
Close=59.419998, Volume=12768200, Adj Close=51.825539)


Row(Date='2012-01-06', Open=59.419998, High=59.450001, Low=58.869999,
Close=59.0, Volume=8069400, Adj Close=51.45922)


Row(Date='2012-01-09', Open=59.029999, High=59.549999, Low=58.919998,
Close=59.18, Volume=6679300, Adj Close=51.616215000000004)
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 6. 使用describe()查看DataFrame

```
+-------+----------+-----------------+-----------------+------------
----+-----------------+-----------------+-----------------+
|summary|      Date|             Open|             High|
Low|            Close|           Volume|        Adj Close|
+-------+----------+-----------------+-----------------+------------
----+-----------------+-----------------+-----------------+
|  count|      1258|             1258|             1258|
1258|             1258|             1258|             1258|
|   mean|      null| 72.35785375357709|72.83938807631165| 71.918600959
4594|72.38844998012726|8222093.481717011|67.23883848728146|
| stddev|      null|  6.76809024470826|6.768186808159218|6.74407575625
5496|6.756859163732991|  4519780.8431556|6.722609449996857|
|    min|2012-01-03|56.389998999999996|        57.060001|        56.29
9999|        56.419998|          2094900|        50.363689|
|    max|2016-12-30|         90.800003|        90.970001|            8
9.25|        90.470001|         80898100|84.91421600000001|
+-------+----------+-----------------+-----------------+------------
----+-----------------+-----------------+-----------------+
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 7. 在describe()中，mean和stddev的小数位数太多。将数字设置为最多显示两位小数。

提示：可以使用 format_number方法

summary	Open	High	Low	Close	Volume
count	1,258.00	1,258.00	1,258.00	1,258.00	1258
mean	72.36	72.84	71.92	72.39	8222093
stddev	6.77	6.77	6.74	6.76	4519780
min	56.39	57.06	56.30	56.42	2094900
max	90.80	90.97	89.25	90.47	80898100

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 8. 创建一个新的dataframe，其中包含一个名为HV Ratio的列，该列是一天内股票最高价与交易量的比率

```
+--------------------+
|            HV Ratio|
+--------------------+
|4.819714653321546E-6|
|6.290848613094555E-6|
|4.6694129947839l6E-6|
|7.367338463826307E-6|
|8.915604778943901E-6|
|8.644477436914568E-6|
|9.351828421515645E-6|
| 8.29141562102703E-6|
|7.712212102001476E-6|
|7.071764823529412E-6|
|1.015495466386981E-5|
|6.576354146362592...|
| 5.90145296180676E-6|
|8.547679455011844E-6|
|8.420709512685392E-6|
|1.041448341728929...|
|8.316075414862431E-6|
|9.721183814992126E-6|
|8.029436027707578E-6|
|6.307432259386365E-6|
+--------------------+
only showing top 20 rows
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 9. 查看最高价最高的的一天

```
[Row(Date='2015-01-13', Open=90.800003, High=90.970001, Low=88.93, Clo
se=89.309998, Volume=8215400, Adj Close=83.825448)]
```

```
'2015-01-13'
```

- 10. 收盘价(Close)的平均值

```
+-----------------+
|      avg(Close)|
+-----------------+
|72.38844998012726|
+-----------------+
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 11.成交量(Volume)的最大和最小值

```
+-----------+-----------+
|max(Volume)|min(Volume)|
+-----------+-----------+
|   80898100|    2094900|
+-----------+-----------+
```

- 12. 收盘价低于60的总天数

```
81
```

```
+------------+
|count(Close)|
+------------+
|          81|
+------------+
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 13. 最高价大于80占总天数的百分比

--- --- (High > 80 的天数) / 总天数

```
9.141494435612083
```

- 14. 最高价和成交量之间的皮尔逊系数是多少（Pearson correlation）

```
+------------------+
| corr(High, Volume)|
+------------------+
|-0.3384326061737161|
+------------------+
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 15. 每一年中最高价是多少

```
+----+---------+
|Year|max(High)|
+----+---------+
|2015|90.970001|
|2013|81.370003|
|2014|88.089996|
|2012|77.599998|
|2016|75.190002|
+----+---------+
```

Spark DataFrame

❑ Spark DataFrame 作业

◆数据集：walmart_stock.csv （2012-2017 沃尔玛股票数据）

➢ 使用walmart_stock.csv文件回答并完成以下任务！

- 16. 每个月的平均收盘价是多少?

  换句话说，在所有年份中，1月、2月、3月...每个月的平均收盘价是多少.....

```
+-----+-----------------+
|Month|       avg(Close)|
+-----+-----------------+
|    1|71.44801958415842|
|    2|  71.306804443299|
|    3|71.77794377570092|
|    4|72.97361900952382|
|    5|72.30971688679247|
|    6| 72.4953774245283|
|    7|74.43971943925233|
|    8|73.02981855454546|
|    9|72.18411785294116|
|   10|71.57854545454543|
|   11| 72.1110893069307|
|   12|72.84792478301885|
+-----+-----------------+
```

```
sc.stop()
```